



부산대학교 인문대학 디지털인문학센터
글로벌대학30 · 2026 여름워크숍

스캔한 옛 책에서 글자 꺼내기

부산대학교 여름워크숍 · 비정형 사료의 디지털화

3차시 8월 11일 15:00 – 17:00

강사

정송이 한국학중앙연구원 디지털인문학연구소 연구원



■ 오늘 하는 일

1 굽어보기

이 PDF에 글자가 들어 있나 — 손으로 확인합니다

2 꺼내보기

사진으로 바꾸고, 글자를 베끼고, 문맥으로 고칩니다

3 따져보기

내 자료에도 되는가 — 언어와 시대별로 갈립니다

손을 쓰는 것은 1번과, 2번의 뒷부분. 두 번입니다.

■ 부족한 것은 늘 시간입니다

전공에 따라 현대 한국어부터 근현대 국한문, 조선시대 한문까지 서로 다른 사료를 읽어야 하고 또 읽을 수 있습니다.

부족한 것은 읽는 능력이 아니라 **옮겨 적을 시간**입니다.

비용을 치르고 시간을 얻는 거래입니다

한 장 처리에 수십 원 수준입니다. 대신 기초 자료를 모으고 발췌하는 시간이 줄어듭니다.
OCR은 판독 능력을 대신하는 것이 아니라, 옮겨 적는 손을 대신하는 것입니다.

■ 무엇이 줄어드는지 분명히 해야 합니다

줄어드는 것

옳게 적는 시간

줄지 않는 것

대조하는 시간

오늘 만드는 것은 완성본이 아니라 1차 가공물입니다

코 랩

두 파일을 열어 마우스로 굽어보세요

A 굽어보기_A_부산광복60년.pdf

B 굽어보기_B_부산구술사총서.pdf

잘 안 되셔도 괜찮습니다. 화면만 보셔도 됩니다.

둘 다 굵혔는데, 하나는 0자입니다

브라우저에서 열면

A · B 둘 다 굵힌다

한글 뷰어로 열면 A는 굵히지 않습니다

파일 안을 열어보면

A는 0자

B는 4,809자

브라우저가 그 자리에서 읽어준 것입니다. 파일에 들어 있는 글자가 아닙니다.

스캔본은 글자가 아니라 그림입니다

그림층

종이를 찍은 사진입니다.
사람 눈에는 글자로 보이지만
컴퓨터에게는 점의 배열입니다.

글자층

그림 위에 얹힌 투명한 글자입니다.
이것이 있어야 굵히고, 검색되고,
옳게 쓸 수 있습니다.

OCR이 하는 일은 이 그림에서 글자를 읽어내는 것입니다.

344쪽 전체가 0자입니다

0 자

자료로 본 부산광복 60년
344쪽 가운데 글자가 있는 쪽 0쪽
한 쪽도 예외가 없습니다

304,759

구술로 보는 부산음악의 역사
379쪽 가운데 377쪽에 글자가 있습니다
이 자료는 OCR이 필요 없습니다

확인에 걸린 시간 0.8초. 먼저 재보고 시작합니다.

OCR — 광학 문자 인식

Optical Character Recognition 의 약자입니다.

Optical

광학

빛으로 본다는 뜻입니다.
스캔하거나 사진으로 찍은
이미지를 봅니다.

Character

문자

낱낱의 글자입니다.
문장이나 뜻이 아니라
글자 하나하나입니다.

Recognition

인식

알아본다, 맞힌다는 뜻입니
다.

「이해」가 아닙니다.

「인식」이지 「이해」가 아닙니다.

무슨 내용인지는 모르는 채로, 글자 모양만 보고 맞힙니다.

OCR이 하는 일

사진 속 글자 모양을 보고, 그것이 어떤 문자인지 맞추는 것.

- 모양만 본다

앞뒤 문맥을 모릅니다. 「日」과 「曰」은 획 하나 차이입니다

.

- 확신을 함께 준다

날말마다 몇 퍼센트 자신 있는지 알려주는 도구가 있습니다.

- 틀린 자리를 말해주지 않는다

0.99로 자신 있게 틀리기도 합니다.

■ 기관이 준 텍스트가 늘 내 연구에 맞지는 않습니다

애초에 없다

디지털화가 안 된 자료. 오늘 다루는 344쪽이 그렇습니다.

있는데 품질이 나쁘다

세로쓰기 · 국한문 · 저품질 스캔에서 무너집니다.

있는데 내려받을 수 없다

화면에서만 보이고 파일로 주지 않는 경우.

있는데 범위가 다르다

필요한 쪽이 빠져 있거나, 판본이 다릅니다.

맞지 않으면 직접 뽑습니다.

코 랩

이제 꺼내 보겠습니다

- step 0 PDF를 사진으로 꺼낸다
- step 1 구글 비전 — 모양만 보고 베킨다
- step 2 제미나이 — 뜻을 알고 고친다

한 장에 15초. 344쪽을 다 바꾸는 것이 아닙니다.

■ 방금 나온 것은 판독문이 아닙니다

글자가 쏟아져 나왔지만, 어디가 틀렸는지는 아무도 말해주지 않았습니다.

1차 가공물

연구자가 원본과 대조해야 비로소 쓸 수 있는 상태입니다.

인용하려면 그 대조를 거쳐야 하고, 그 시간은 줄지 않았습니다.

옳게 적는 손을 덜었을 뿐입니다.



휴식 10분



왜 두 단계로 하나요?

한 번에 되면 더 편할 텐데요.

이 한 쪽으로 비교했습니다

여성사적의 변화

201

에 고황경이 취임하였고 이내 명칭을 부녀국으로 하였다. 그 후 지방 부녀 행정조직에 착수하여 1947년 10월 전국 각 시·도의 보건 후생국 후생과 내에 부녀계를 설치하였다.

부산의 경우 1947년 부녀계가 보건후생국 후생과에 설치되었고, 1949년에는 문교사회국 사회과 소속으로 이전 편성되었다.

고황경은 취임 후 각 지역의 부녀계 설치에 착수하였는데, 지방에 가서 간담회를 하고 지방조직실행위원회를 조직하여 부녀계 설치를 지원하도록 하였다. 경상남도 실행위원장에는 김로전이, 부위원장에는 김필애, 방덕수를 포함한 25인이 선출되었고, 이 결과로 부녀계가 1947년 10월에 설치되었다. 미군정은 부녀국 조직을 통하여 여성운동의 좌익단체들을 배제하고, 우익여성들을 끌어들이고자 하였다.

한편 부산지역에서는 여성단체들이 중심이 되어 6.25로 인한 전쟁미망인이나 윤락여성들의 생계문제에 관심을 둔 여성복지 사업이 이루어졌다.

1955년 중앙 행정조직의 사회부와 보건부가 보건사회부로 통합되자 기존의 지도과·보호과·보건과는 부녀과·생활과·아동과로 부서명이 바뀌었다. 보건사회부는 6.25전쟁으로 인해 전쟁미망인과 윤락여성이 증가하였기 때문에 국립모자원등을 설치하여 이들이 자립 생계를 유지할 수 있도록 직업보도를 하는 등 전쟁미망인 구호사업과 윤락여성보호사업에 치중하였다.

자료로 본 부산광복 60년

201쪽 「여성사회의 변화」

- 순한글 가로쓰기
- 단이 하나
- 사진·목록 없음
- 약 690자

한자가 섞이지 않았습니다

신문처럼 여러 단으로 나뉘지 않았습니다

본문 글자만 있습니다

한 쪽 분량입니다

가장 쉬운 조건입니다. 여기서 안 되면 다른 자료에서는 더 안 됩니다.

세 가지 방식으로 각각 돌려봤습니다

	뽑힌 글자	걸린 시간	핵심어 13개
비전만	689자	1.0초	13 / 13
제미나이만	682자	7.6초	13 / 13
비전 → 제미나이	752자	9.3초	13 / 13

핵심어 13개 — 틀리면 곤란한 낱말입니다. 사람 이름, 기관 이름, 연도 같은 것들.

제미나이 혼자서도 13개를 다 맞혔습니다. 「김로전」까지 정확히 읽었습니다.

깨끗한 현대 한국어에서는 두 단계라야 더 정확한 것이 아닙니다.

200쪽을 뽑았습니다. 어디부터 보시겠습니까

기계가 뽑은 글은 매끄럽습니다. 틀린 자리에서도 매끄럽습니다.

한 단계로 뽑으면

어느 낱말이 미심쩍은지 표시가 없습니다.

200쪽을 처음부터 다시 읽는 수밖에 없습니다.

비전을 함께 쓰면

낱말마다 「이건 자신 없다」는 표시가 붙습니다.

표시된 곳부터 봅니다.

더 잘 읽으려는 것이 아니라, 어디를 의심할지 알려는 것입니다.

가운뎃점 하나가 부서 셋을 하나로 만듭니다

201쪽 본문에서

되자 기존의 지도과 · 보호과 · 보건과는 부녀과 · 생활과 · 아동과

이 가운뎃점을 기계는 0.39의 확신으로 읽었습니다.

「자신 없다」는 뜻입니다. 놓치면 「지도과 보호과 보건과」가 되어, 셋인지 하나인지 알 수 없게 됩니다.

자신 없어 한 낱말 6개가 전부 문장부호였습니다.

가운뎃점 0.39 · 0.41 · 0.42 · 0.51

마침표 0.73 · 0.76

한글은 오히려 잘 읽었습니다.

코 랩

각자 노트북을 열어 주세요

- ① 설치와 자료 받기
- ② 열쇠 등록 드라이브 연결을 허용하세요
- ③ 설정 고치는 칸은 여기 하나뿐입니다
- ④⑤ 사진 만들기·확인 오늘은 여기까지
- ⑥부터는 열쇠가 필요합니다. 각자 돌리는 것은 내일 합니다.

■ 내 자료는 되는가

	쉬움	어려움
영어	현대 인쇄물	—
한국어	현대	근현대 — 세로쓰기 · 국한문 · 옛활자
한문	조선시대 인쇄본 정자	필사본 초서 · 행서, 근현대 한자
일본어	현대 / 역사시대 초서	근현대 — 루비 · 구자체 · 다단

가장 어려운 칸이, 우리가 자주 쓰는 자료입니다.

■ 영어가 쉬운 이유

「개발 언어가 영어라서」가 아닙니다. 프로그래밍 언어와 정확도는 무관합니다.

1

글자 수

라틴 알파벳 100자 미만
한글 실사용 2,350자
한자 수만 자

2

자형 구별도

라틴 문자는 서로 안 닮았습니다
한자는 획 하나로 갈립니다
日 / 日 未 / 末 士 / 土

3

학습 데이터 양

영어 인쇄물 데이터가
압도적으로 많습니다

이것이 가장 큼니다

「조선시대 한문은 잘 된다」고 하면 안 됩니다

된다

목판본 · 활자본의 정자(楷書)
글자 모양이 규칙적이고
간격이 일정합니다

전혀 다른 문제

필사본 초서 · 행서
이체자, 피휘, 구두점 없는 세로쓰기가
한꺼번에 겹칩니다

뭉뚱그려 말하면 고문서 전공자가 그 자리에서 반례를 댁니다.

일본 역사시대가 쉬운 이유

일본어가 쉬워서가 아닙니다.

국립국회도서관이 초서(くずし字) 전용 OCR을 **국가사업으로 만들었습니다.**

범용 도구에 초서를 넣으면 무너집니다.

그런데 근대 활자는 아직 안 풀렸습니다. 루비 · 구자체 · 다단이 겹칩니다.

기관이 만들어준 도구가 있으면 그것을 쓰는 편이 낫고,
없으면 연구자가 직접 조정해야 합니다.



오늘의 결론

기계는 빠르지만 틀립니다.
그리고 틀린 자리를 스스로 알려주지 않습니다.

원본과 나란히 놓고 보는 습관이, 도구를 쓰는 능력보다 중요합니다.

줄어드는 것은 옮겨 적는 시간입니다. 대조하는 시간은 줄지 않습니다.



■ 내일 하는 일

■ 각자 돌려보기

어제 ⑤까지 보신 것을, 오늘은 ⑥부터 직접 돌립니다

■ OCR의 어제와 오늘

형태를 대조하던 방식에서, 문맥이 형태를 메우는 방식으로

■ 사진과 목록이 있는 쪽

글자만 있는 쪽과 무엇이 다른지 직접 넣어봅니다

■ 빠뜨린 것을 세어보기

열다섯 항목 중 몇 개가 살아남았는지 대조합니다

■ 근대 신문에 넣어보기

세로쓰기 · 국한문 · 명단 — 어디서 무너지는지 봅니다

열쇠를 아직 못 받으신 분은 오늘 밤에 안내문을 한 번 더 보고 오세요.