



부산대학교 인문대학 디지털인문학센터
글로벌대학30 · 2026 여름워크숍

사진과 목록이 있는 쪽

부산대학교 여름워크숍 · 비정형 사료의 디지털화

4차시 8월 12일 15:00 – 17:00

강사

정송이 한국학중앙연구원 디지털인문학연구소 연구원



어제 어디까지 했나

어제 끝낸 것

사진 만들기까지

설치 · 열쇠 · 설정 · 사진 만들기

오늘 처음 하는 것

글자 꺼내기부터

글자 베끼기 · 문맥 교정 · 세어보기

어제는 제 화면으로만 보셨습니다. 오늘은 각자 독립니다.

■ 오늘 하는 일

1 돌려보기

어제 화면으로만 보신 비전·제미나이를 오늘은 각자 돌립니다

2 세어보기

열다섯 줄 가운데 몇 개가 살아남았는지 원본과 맞춥니다

3 근대 지면

세로쓰기 · 국한문 · 명단 — 어디서 무너지는지 봅니다

손을 쓰는 것은 1번과 2번. 오늘은 손이 45분입니다.

■ 오늘의 질문은 다릅니다

어제

틀리게 읽었나

가운뎃점 · 오식 · 지어낸 이름

오늘

없어졌나

목록 · 명단 · 사진 설명

틀린 것은 눈에 띄니다. 없어진 것은 세어봐야 압니다.

2008년, 호주국립도서관

읽기자료 ① 로즈 홀리

옛 신문을 기계로 읽히는 일을 몇 해 해본 뒤에 쓴 보고입니다.

■ 호주 지명 사전을 넣어주기

오히려 나빠졌다 — 이유를 못 밝힘

■ 흑백 대신 회색 단계로

거의 그대로 (93.8% → 94.0%)

■ 이미지 다듬는 프로그램 교체

거의 그대로

손덜 만한 데를 다 손대봐도 크게 나아지지 않았습니다.

■ 결국 사람이 고쳤습니다

가장 효과가 컸던 것은 기술이 아니라, 읽는 사람에게 고치게 한 것이었습니다.

70만 줄

공개하고 12주 만에
약 1,200명이 5만 건의 기사에서

그때 하고 싶었는데 못 한 것

앞뒤 문맥으로 메우기

"the cot sat on the met" 보다

"the cat sat on the mat" 이 그럴듯하다

— 사람도 시간도 없어 못 해봤다



2008년에 하고 싶었지만
못 했던 그 일을,
지금은 모델이 그냥 합니다.

모양을 맞춰보던 방식에서, 문맥으로 메우는 방식으로.

그런데 문맥이 없는 자료에서는 어떻게 될까요.

코 랩

두 쪽을 넣어봅니다

- A 사진이 있는 쪽 부산광복 60년 발췌본 3쪽
- B 목록이 있는 쪽 내사랑 부산바다 243쪽

교정지시는 어제 쓰던 그대로입니다. 사진과 목록 이야기는 한 줄도 없습니다.

B 쪽은 이렇게 생겼습니다

내사랑 부산바다 243쪽

옛 지명과 일제강점기 지명을 짝지은 목록

■ 열다섯 줄

동광동(東光洞) - 본정(本町)과 상반정(常盤町)
)

■ 사진이 목록을 가름

위에 다섯 줄, 아래 열 줄

■ 설명이 그 사이에

「영도대교가 놓여지기 이전...」

■ 한자 병기

괄호 안이 전부 한자입니다

제2권 / 부산항의 변천

동광동(東光洞) - 본정(本町)과 상반정(常盤町)
중앙동(中央洞) - 대왕정(大倉町)과 좌동정(佐倉町)과 고도정(高島町)과 경부정(京釜町)
대왕정(大倉町) - 대왕정(大倉町)
북평동(北平洞) - 현 대왕동에 편입) - 북평정(北平町)
대교동(大橋洞) - 현 중앙동에 편입) - 대교정(大橋町)과 북안정(北安町)



▲ 영도대교가 놓여지기 이전 영도에서 바라본 부산항(1930년대 초로 추정됨)

신왕동(新王洞) - 현 광복동에 편입) - 서정(西町)
광산동(光善洞) - 현 광복동에 편입) - 행정(幸町)
남포동(南浦洞) - 남민정(南民町)
충무동(忠武洞) - 소와동(昭和洞)
보수동(寶水洞) - 보수정(寶水町)
부평동(富平洞) - 부평정(富平町)
부민동(富民洞) - 부민정(富民町)
서대산동(西大新洞) - 서대산정(西大新町)
남부민동(南富民洞) - 남부민정(南富民町)
초상동(草場洞) - 초상정(草場町)

짜이 맞는 목록이라, 몇 개가 살아남았는지 셀 수 있습니다.

■ 몇 개가 남았습니까

화면에 뜬 숫자를 원본과 맞춰 보세요.

비전이 읽은 것

모양만 보고 베꼈습니다.

목록이든 문장이든 상관하지 않습니다.

제미나이가 고친 뒤

문맥으로 읽는 도구입니다.

목록에는 기댔 문맥이 없습니다.

에러가 나지 않습니다. 결과물은 멀쩡해 보입니다.

■ 사진은 어떻게 됐습니까

A 쪽 사진에는 현판과 펼침막의 글자가 찍혀 있습니다.

■ 사진 속 글자

본문 사이에 끼어들었습니까?

■ 사진 설명

본문과 구분되어 있습니까, 섞여 있습니까?

■ 사진이 있던 자리

결과에서는 어떻게 표시되어 있습니까?

교정지시에는 사진 이야기가 한 줄도 없었습니다. 말하지 않은 것은 처리되지 않습니다.



휴식 10분

세로로 늘어선 것을 기계가 헛갈립니다

읽기자료 ② 이서준 · 김병준 · 전봉관 (2024)

조선일보 지면 47,777장에서 네컷만화가 실린 자리를 자동으로 찾아낸 연구입니다.

찾으려던 것

네 칸이 세로로 늘어선 만화

잘못 짚은 것

세로로 길게 박힌 제호(한자)
세로 광고

글자를 한 자도 읽지 않는 연구인데도 같은 문제가 나옵니다.

지금부터 볼 지면이 전부 세로쓰기입니다.

코 랩


근대 지면을 넣어보겠습니다

1단	부산광복 60년 201쪽	가로쓰기 · 순한글 · 단 하나
2단	부산대학보 1957 1면	세로쓰기 · 국한문 · 다단
3단	부산대학보 1957 3면	+ 졸업생 478명 명단

코드는 어제 것 그대로입니다. 자료만 바꿉니다.


자신 없어 하는 비율

1단 부산광복 201쪽



2%

2단 학보 1면



32%

3단 학보 3면 명단



58%

코드는 한 줄도 안 고쳤습니다. 자료가 바뀌었을 뿐입니다.

어제 자료에서 헛갈린 것은 가운데점 몇 개뿐이었습니다. 명단면에서는 절반이 넘습니다.

■ 코드가 아니라 지시문을 고칩니다

세로쓰기라는 것, 국한문이라는 것, 구자체를 신자체로 바꾸면 안 된다는 것 — 이런 것은 코드가 아니라 지시문에 들어갑니다.

어제의 지시문 → 신문용 지시문

세로쓰기 판독 순서 · 다단 구분 · 국한문 보존 · 표와 명단의 행과 열 유지
그리고 「한 글자라도 확신할 수 없으면 그 글자 뒤에 [?] 를 붙여라」

이것이 「사료 지식을 넣는다」는 말의 실제 내용입니다.

■ 어제 이야기가 여기서 뒤집힙니다

어제 「불확실하면 □ 로 표시하라」고 시켰는데 하나도 안 나왔습니다.

학보 1면	[?]	□
어제의 지시문	0개	0~1개
신문용 지시문	30개	23개


기계가 정직해진 것이 아니라, 정직하게 시킨 것입니다.


「불확실하면 표시하라」로는 부족합니다. 「그 글자 뒤에 [?] 를 붙여라」라고 해야 합니다.

그래도 넘지 못하는 선

명단면 오른쪽에 네 자리 학번이 286개 있습니다. 비전은 읽어냈습니다.

비전이 읽은 것  286개

신문용 지시문 뒤  29개

어제 지시문 뒤  2개

「표와 명단의 행과 열을 유지하라」고 명시했는데도 90%가 사라졌습니다.

오전에 목록에서 보신 것과 같은 일입니다. 규모만 커졌습니다.



명단에는 문맥이 없습니다.

LLM은 문맥으로 읽는 도구입니다.

문맥이 없는 자리에서는 기댈 것이 없습니다.

이것은 오류가 아닙니다. 에러 메시지가 없습니다. 그저 조용히 없어집니다.

명단 · 통계표 · 색인 · 목록 — 사료에는 이런 것이 아주 많습니다.



이틀 동안

- **파이프라인은 범용입니다**

자료가 바뀌어도 코드는 그대로입니다

- **지시문에 사료 지식을 넣습니다**

구체적으로 시켜야 작동합니다

- **그래도 넘지 못하는 선이 있습니다**

목록과 명단은 조용히 사라집니다

도구를 쓰는 능력보다, 어디까지 맡길지 아는 판단이 중요합니다.

다시 처음으로

줄어드는 것

옳게 적는 시간

줄지 않는 것

대조하는 시간

이틀 동안 함께해 주셔서 감사합니다.

정송이 songi113@hanmail.net

