

4차시 읽기자료

부산대학교 여름워크숍 · 비정형 사료의 디지털화 · 4차시 (8/12)

강의에서 짚는 논문 두 편을 정리했습니다.

	논문	언제
①	로즈 홀리 (2009) — 옛 신문을 기계로 읽히면 얼마나 맞나	15:00
②	이서준 · 김병준 · 전봉관 (2024) — 신문 지면에서 네컷만화 찾아내기	16:05

②는 글자를 읽는 연구가 아니라, 지면 어디에 그림이 있는지를 찾는 연구입니다.

① 로즈 홀리 (2009)

Holley, Rose. 「How Good Can It Get? Analysing and Improving OCR Accuracy in Large Scale Historic Newspaper Digitisation Programs」, *D-Lib Magazine* 15(3/4), 2009.

- DOI: 10.1045/march2009-holley
- http://www.dlib.org/dlib/march09/holley/03holley.html
- 사본: http://eprints.rclis.org/12908/

호주국립도서관에서 옛 신문을 디지털로 옮기는 일을 맡았던 사람이, 2007~2008년에 자기들이 해본 것을 정리한 글입니다.

왜 이 글인가

2008년에 기계가 어디까지 와 있었는지를 알려줍니다. 지금과 견줄 기준이 필요한데, 이 글은 짐작이 아니라 직접 재본 숫자를 씁니다. 잘된 것만이 아니라 **해봤는데 안 된 것도 그대로** 적어 두었습니다.

짚어볼 대목

기계는 맞았는지 모른다

이 글에서 가장 오래 남는 대목입니다.

The OCR software doesn’t know whether any character is correct or not

기계는 자기가 옳게 읽었는지를 모릅니다. **얼마나 자신 있는지만** 말할 뿐입니다. 맞았는지 틀렸는지는 사람이 원본과 맞춰봐야 압니다.

그런데 현장에서는 이 둘을 자꾸 같은 것으로 다룹니다. 수십만 쪽을 사람이 다 대조할 수 없으니, 자신 있는 정도를 정확도인 양 쓰는 것입니다.

3차시에 보신 「**자신 없어 한 낱말**」이 바로 이것입니다.

어느 정도면 쓸 만한가

당시 도서관과 업체들 사이에 통하던 눈금입니다.

	글자 단위 정확도
좋다	98~99%
그저 그렇다	90~98%
나쁘다	90% 미만

호주국립도서관이 1803~1954년 신문 45쪽을 재보니 **71%에서 98%까지** 들쭉날쭉했습니다. 71%면 500자짜리 문단에서 145자가 틀립니다.

다만 이 눈금에도 합의가 없었다고 덧붙입니다. 글자를 세는지 낱말을 세는지, 한 쪽 단위인지 기사 단위인지가 사람마다 달랐습니다.

결과가 나쁜 건 기계 탓이 아닐 때가 많다

네덜란드 국립도서관 조사를 인용한 대목입니다. 같은 프로그램을 써도 원본이 낡고 흐리면 결과가 나쁩니다. 어떤 도구를 쓰느냐보다 어떤 자료를 가졌느냐가 더 크게 갈랐다는 뜻입니다.

해봤는데 안 된 것 셋

이 글에서 가장 값진 부분입니다.

해본 것	어떻게 됐나
호주 지명 사전을 따로 넣어주기	오히려 나빠졌다. 왜 그런지 못 밝힘
흑백 대신 회색 단계로 처리하기	거의 그대로 (93.8% → 94.0%)
이미지 다듬는 프로그램 바꾸기	거의 그대로

첫 줄이 눈에 띄니다. 지명을 미리 알려주면 좋아질 줄 알았는데 나빠졌고, 도서관도 업체도 이유를 대지 못했습니다. 프로그램 회사가 속을 공개하지 않았기 때문입니다.

손달 만한 데를 다 손대봐도 크게 나아지지 않았다 — 2008년의 결론입니다.

결국 사람이 고쳤다

가장 효과가 컸던 것은 기술이 아니라 읽는 사람이 직접 고치게 한 것이었습니다. 공개하고 12주 만에 약 1,200명이 5만 건의 기사에서 70만 줄을 고쳤습니다. 고치는 일이 재미있다는 반응이 많았다고 합니다.

하고 싶었는데 못 한 것

여기가 오늘 이 글을 읽는 이유입니다.

글쓴이는 기계가 틀리는 방식에 규칙이 있다는 걸 알아했습니다. 사람의 오타와 달리, h를 li로 m을 in으로 바꿔 읽는 식으로 늘 비슷하게 틀립니다. 그리고 낱말이 만들어진 뒤에는 앞뒤 문맥을 보면 된다고 적습니다. “the cot sat on the met”보다 “the cat sat on the mat”이 훨씬 그럴듯하니까요.

이렇게 하면 크게 좋아질 것 같은데, 사람도 시간도 없어서 못 해봤다고 써두었습니다.

2008년에 하고 싶었지만 못 했던 그 일을, 지금은 모델이 그냥 합니다. 모양을 맞춰보던 방식에서 문맥으로 메우는 방식으로 넘어온 자리가 여기입니다.

읽을 때 주의할 것

- 2008년 글입니다. 지금 쓰는 기술이 나오기 전입니다
- 다룬 자료는 호주에서 나온 영어 신문입니다
- 종이가 아니라 마이크로필름을 스캔한 것이라 조건이 다릅니다
- 한국어나 한자를 다룬 대목은 없습니다

그러니 여기 숫자를 우리 자료에 그대로 옮기시면 안 됩니다. 그때 무엇이 문제였고 무엇을 해봤는지를 보는 글입니다.

② 이서준 · 김병준 · 전봉관 (2024)

Lee, Seojoon, Byungjun Kim, and Bong Gwan Jun. 「Automatic Detection of Four-Panel Cartoon in Large-Scale Korean Digitized Newspapers using Deep Learning」, *Journal of Open Humanities Data* 10: 36, 2024, pp. 1–15.

- DOI: 10.5334/johd.205
- 자료: 10.7910/DVN/DFVZWE (Harvard Dataverse)
- CC BY 4.0 — 마음대로 받아 쓰고 나눠줄 수 있습니다

카이스트 디지털인문사회과학부에서 한 연구입니다.

왜 이 글인가

글자를 읽는 연구가 아닙니다. 무엇이 어디에 있는지를 찾는 연구입니다.

그런데 오늘 오후에 할 일과 뿌리가 같습니다. 신문 한 면을 통째로 넣으면 읽는 순서가 뒤엉키니, 필요한 자리를 먼저 잘라내야 합니다. 이 연구는 그 잘라내는 일을 기계에게 시킨 사례입니다.

짚어볼 대목

무엇을 했나

조선일보 뉴스라이브러리에 있는 1920~1940년 지면 47,777장에서 네컷만화가 실린 자리를 자동으로 찾아냈습니다.

- 기계를 가르치는 데 쓴 그림은 161장뿐입니다
- 그 가운데 113장으로 가르치고, 나머지로 제대로 배웠는지 확인했습니다
- 결과: 1,035장의 지면에서 1,040개를 찾아냄
- 가장 많이 나온 것은 「명탕구리」 726건

가져다 쓴 기계는 아무것도 못 찾았다

널리 쓰이는 YOLOv5를 그대로 돌렸더니 네컷만화를 하나도 찾지 못했습니다. 자동차·자전거·와인잔 같은 여든 가지만 배운 기계였기 때문입니다.

남이 만들어 놓은 도구가 내 자료를 모른다 — 3차시에 말씀드린 그 이야기입니다. 그래서 연구자들이 161장에 일일이 네모를 쳐서 다시 가르쳤습니다.

앞선 연구가 놓친 것을 찾았다

2016년에 사람이 손으로 세어둔 것과 맞춰본 표가 실려 있습니다.

「명탕구리」 연작	사람이 센 것	기계가 찾은 것
기자생활 1부	없음	35건
모던생활	없음	4건
사회사업	50건	62건
헛물켜기	48건	55건
굶주린생활	50건	19건

늘어난 줄도 있고 줄어든 줄도 있습니다. 맨 아래가 기계가 놓친 것입니다. 사람이 찾아둔 50건 중 19건만 잡았습니다.

무엇을 잘못 찾았나

오늘 오후와 가장 가까운 대목입니다.

기계는 세로로 길게 박힌 조선일보 제호(한자)와 세로 광고를 네컷만화로 잘못 짚었습니다. 네 칸이 세로로 늘어선 모양과 닮았기 때문입니다.

기계가 찍어낸 것이 4,508장이었는데 진짜는 1,035장이었습니다. 나머지는 사람이 눈으로 걸러냈습니다.

세로로 늘어선 것을 기계가 헛갈린다. 오후에 부대신문에서 만날 문제와 뿌리가 같습니다.

코랩으로 공개했다

가르친 기계를 구글 코랩에 올려두어, 누구나 자기 그림을 넣고 돌려볼 수 있습니다. 찾아낸 만화들의 주소도 엑셀로 정리해 공개했습니다.

읽을 때 주의할 것

- 글자는 한 자도 읽지 않습니다. 자리만 찾습니다
- 가르치는 데 쓴 그림이 161장으로 적습니다. 연구자들도 이를 한계로 밝혔습니다
- 잘못 짚는 문제를 풀지 못한 채 논문이 나왔습니다. 사람이 걸려야 합니다
- 조선일보 지면이 대상입니다. 지면 생김새가 다르면 그대로 되지 않습니다

두 글을 나란히 놓으면

	홀리 (2009)	이 · 김 · 전 (2024)
하는 일	글자를 읽는다	자리를 찾는다
결론	기술로는 한계, 사람이 고쳐야 했다	기계가 찾고, 사람이 걸러냈다

16년 사이에 기계는 훨씬 좋아졌습니다. 그런데 둘 다 사람이 확인하는 자리를 없애지는 못했습니다.

줄어드는 것은 옮겨 적는 시간이고, 대조하는 시간은 줄지 않습니다.